

Asignatura: Ciencia de Datos

Integrantes: David Célleri, José Solórzano

Fecha: 29 de septiembre de 2026

1. Herramienta y categoría

- **Herramienta principal:** PyCaret (librería de AutoML de código abierto en Python).
- **Categoría:** AutoML, etapa de **modelado** del ciclo de vida de los datos, con evaluación de modelos.

2. Conjunto de datos

- **Nombre:** Telco Customer Churn (IBM Sample Data).
- **Fuente:** Kaggle, <https://www.kaggle.com/datasets/blastchar/telco-customer-churn> (listado en el anexo de fuentes de datos, categoría AutoML).
- **Formato y tamaño:** CSV, 7.043 filas × 21 columnas, menos de 1 MB.
- **Variable objetivo:** *Churn* (sí/no).
- **Licencia:** dataset de muestra de IBM publicado en Kaggle. Pendiente de confirmar por el profesor. Plan B: Bank Marketing (UCI), con licencia CC BY 4.0.

3. Pregunta o problema

¿Puede PyCaret igualar o superar el desempeño de una regresión logística hecha a mano en scikit-learn al predecir el abandono de clientes, y con qué costo en tiempo y esfuerzo de programación?

El pipeline incluirá carga y revisión del dataset, preparación básica, entrenamiento con ambos enfoques, evaluación y análisis, todo en un notebook reproducible en GitHub.

4. Herramienta alternativa y criterios de comparación

- **Alternativa:** regresión logística manual con scikit-learn (imputación, *one-hot encoding*, escalado y validación cruzada). H2O AutoML solo como referencia bibliográfica.
- **Criterios medibles con datos del pipeline:**
 1. **Desempeño:** AUC-ROC, F1 y recall de la clase "abandona", con la misma partición y validación cruzada de 5 folds.
 2. **Tiempo de ejecución:** segundos de entrenamiento y selección de modelo.
 3. **Líneas de código** necesarias para llegar al modelo final.
 4. *(Cualitativo)* Interpretabilidad y control sobre el proceso.

5. Roles

Integrante	Rol principal	Responsabilidades
------------	---------------	-------------------

David Céleri	Pipeline con PyCaret y repositorio	Configuración de PyCaret, comparación de modelos, gestión del repositorio en GitHub, README
José Solórzano	Línea base y material educativo	Regresión logística en scikit-learn, métricas y tablas de comparación, presentación/guía y video

Ambos participan en el EDA, las conclusiones, la declaración de uso de IA y la revisión cruzada del trabajo del otro.